RELATÓRIO - AGROSEARCH: MOTOR DE BUSCA INTELIGENTE

Instituição: UNIPÊ | **Disciplina:** Tópicos Avançados - Recuperação de Informação / PLN
Professor: Me. Ricardo Roberto de Lima
Aluno: Joao Victor Araujo de Andrade

1. Objetivo

O AgroSearch foi desenvolvido como um protótipo de motor de busca textual para uma base de documentos sobre agricultura. A aplicação permite que o usuário digite uma consulta e receba os documentos mais relevantes, aplicando os conceitos estudados de pré-processamento de texto, índice invertido e TF-IDF. A interface foi construída em Python com Streamlit.

2. Base de documentos

Doc.	Conteúdo
1	Soja, irrigação e período de floração.
2	Controle biológico de lagartas na soja com Trichogramma.
3	Adubação verde, leguminosas, nitrogênio e milho.
4	Lagartas desfolhadoras, soja e algodão.
5	Irrigação por gotejamento, economia de água e cultivo orgânico.

3. Fase 1 - Pipeline de pré-processamento

O texto passa por quatro etapas. Na **tokenização**, expressões regulares separam o texto em palavras. Na **normalização**, os termos são convertidos para minúsculas e os acentos são removidos. Em seguida, a aplicação pode remover **stopwords**, isto é, palavras muito frequentes com baixo valor para a busca. Por fim, um **stemming simples** reduz determinados sufixos. Stopwords e stemming podem ser ligados ou desligados por checkboxes, permitindo observar dinamicamente a alteração do vocabulário.

4. Fase 2 - Índice invertido

Após o pré-processamento, é construído em memória um índice no formato **Termo -> [IDs dos documentos]**. Assim, em vez de percorrer todos os textos para descobrir onde uma palavra aparece, o sistema consulta diretamente os documentos associados ao termo. O índice é gerado a partir dos tokens limpos e exibido na interface.

5. Fase 3 - Busca e ranqueamento TF-IDF

A consulta digitada pelo usuário passa pelo mesmo pipeline aplicado aos documentos. Para cada termo da consulta, o sistema calcula manualmente TF, DF, IDF e TF-IDF, sem utilizar TfidfVectorizer ou scikit-learn. As fórmulas adotadas são **TF(t,d) = frequência(t,d) / total de termos(d)** e **IDF(t) = ln(N / DF(t))**. O valor TF-IDF é obtido pelo produto TF x IDF. Em consultas com múltiplos termos, os valores são acumulados por documento e o ranking é ordenado do maior para o menor, destacando o documento mais relevante.

6. Bônus - Similaridade de Cosseno

Como recurso adicional, foi implementada manualmente a Similaridade de Cosseno entre o vetor TF-IDF da consulta e os vetores dos documentos. O cálculo utiliza o produto escalar dividido pelo produto das normas dos vetores. Esse ranking é apresentado separadamente do TF-IDF e auxilia principalmente em consultas formadas por múltiplas palavras.

7. Conclusão

O AgroSearch integra, em uma única aplicação interativa, os principais conceitos trabalhados nas práticas: pré-processamento, índice invertido e TF-IDF. A solução permite visualizar as etapas do processamento e compreender como os documentos são recuperados e ranqueados conforme a consulta. A implementação dos cálculos e estruturas foi realizada de forma explícita, mantendo o caráter didático proposto para a atividade.